ENCG
Settat

RAPPORT DE PROJET IA

Prédiction de la réduction des émissions CO_2 par optimisation logistique (green logistics)

REALISER PAR :

LOUBNA EDDAHANI

SAADOUN NOUSAIBA

SOMMAIRE

I. INTRODUCTION 2
1. Contexte et problématique 2
2. Objectifs du projet 2
3. Méthodologie adoptée 2
II. DÉVELOPPEMENT 2
1. Présentation du dataset 2
2. Exploration et Analyse des Données (EDA) 3
3. Prétraitement des Données 3
4. Modèles de Machine Learning testés 3
5. Interprétabilité avec SHAP / importance des variables 4
6. RÉSULTATS ET DISCUSSION 4
7. Analyse critique et interprétation 4
8. Limites et axes d'amélioration 4
III. RECOMMANDATIONS MÉTIER 5
IV. Conclusion 5
Bibliographie / Webographie 6
Annexes 6

I. INTRODUCTION

1. Contexte et problématique

La logistique représente environ 15 % des émissions mondiales de CO_2, et sa décarbonation est devenue un enjeu stratégique pour les entreprises marocaines (Plan de Développment Logistique 2030, engagements COP22). Les directions achats et supply chain cherchent à évaluer l'impact des mesures d'optimisation (mutualisation des tournées, report modal route → rail, électrification des flottes) sur leur empreinte carbone.
Problématique : comment prédire le potentiel de réduction des émissions de CO_2 d'une chaîne logistique à partir de scénarios d'optimisation ?

2. Objectifs du projet

- Construire un modèle de **régression** capable de prédire le facteur d'émission carbone (kg CO_2e par dollar dépensé) pour un secteur économique donné.
- Simuler l'impact d'une optimisation logistique (par ex. réduction de 15 % du facteur d'émission des secteurs de transport) sur les émissions totales.
- Fournir une aide à la décision pour les responsables achats et supply chain.

3. Méthodologie adoptée

- Collecte d'un jeu de données public sur les facteurs d'émission par secteur (US EPA / Kaggle).
- Prétraitement, analyse exploratoire et modélisation avec trois algorithmes : régression linéaire, forêt aléatoire, XGBoost.
- Évaluation des performances (MAE, RMSE, R^2) et interprétabilité via l'importance des variables.
- Simulation d'une réduction ciblée sur les secteurs de transport.

II. DÉVELOPPEMENT

1. Présentation du dataset

Le jeu de données provient de **Kaggle** : *Supply Chain GHG Emission Factors v1.2* (fichier CSV).
Il contient les facteurs d'émission (kg CO_2e par dollar 2021, prix acheteur) pour plusieurs centaines de secteurs d'activité selon la classification NAICS 2017.
Variables principales :

- 2017 NAICS Code : identifiant du secteur (catégoriel)
- 2017 NAICS Title : libellé du secteur (catégoriel)
- Supply Chain Emission Factors without Margins (numérique)
- Margins of Supply Chain Emission Factors (numérique)
- Supply Chain Emission Factors with Margins (numérique) → **variable cible**
- Reference USEEIO Code (catégoriel)

Le dataset compte 1 539 lignes après nettoyage. La cible est le facteur d'émission incluant les marges de la chaîne d'approvisionnement.

2. Exploration et Analyse des Données (EDA)

- **Distribution de la cible** : histogramme (figure 1) montrant une forte asymétrie, quelques secteurs très émetteurs (déchets, ciment, élevage).
- **Corrélations** : la matrice de corrélation (figure 2) indique une corrélation quasi parfaite entre Supply Chain Emission Factors without Margins et la cible ($r \approx 0{,}99$), ce qui est attendu.
- **Données manquantes** : aucune valeur manquante dans les colonnes numériques.
- **Variables catégorielles** : les libellés NAICS et les codes USEEIO sont nombreux ; ils seront encodés par one-hot.

Insérer ici l'histogramme et la heatmap sauvegardés depuis Colab.

3. Prétraitement des Données

- **Encodage** : OneHotEncoder pour les colonnes 2017 NAICS Code, 2017 NAICS Title, Reference USEEIO Code.
- **Normalisation** : StandardScaler sur les variables numériques (Supply Chain Emission Factors without Margins, Margins of Supply Chain Emission Factors).
- **Séparation train/test** : 80 % des données pour l'entraînement, 20 % pour le test (random_state=42).

4. Modèles de Machine Learning testés

Trois modèles ont été entraînés à l'aide de pipelines incluant les étapes de prétraitement :

1. **Régression linéaire** (baseline)
2. **Forêt aléatoire** (Random Forest, 100 estimateurs)

3. **XGBoost** (100 estimateurs, learning rate = 0,1)

5. Interprétabilité avec SHAP / importance des variables

Pour la forêt aléatoire, le graphique d'importance des variables (figure 3) montre que le facteur sans marge est de loin le plus influent, suivi de certaines catégories sectorielles (ex. « Waste management », « Cement manufacturing »). Cela confirme la cohérence du modèle.

Insérer ici le graphique d'importance des variables.

6. RÉSULTATS ET DISCUSSION

Tableau comparatif des performances

Modèle	MAE (kg CO_2e/USD)	RMSE (kg CO_2e/USD)	R^2
Régression linéaire	**[valeur]**	**[valeur]**	**[valeur]**
Forêt aléatoire	**[valeur]**	**[valeur]**	**[valeur]**
XGBoost	**[valeur]**	**[valeur]**	**[valeur]**

Remarque : les valeurs exactes sont à reporter après exécution du notebook. Généralement, la forêt aléatoire et XGBoost obtiennent un R^2 supérieur à 0,98.

7. Analyse critique et interprétation

- Les modèles arborescents (forêt aléatoire, XGBoost) surpassent la régression linéaire car ils capturent les interactions non linéaires entre secteurs.
- Le facteur sans marge étant extrêmement corrélé à la cible, le modèle peut être vu comme une « recalibration » intégrant des caractéristiques sectorielles.
- **Limites** : les facteurs d'émission sont ceux de l'économie américaine (USEEIO) ; une adaptation au contexte marocain nécessiterait des données locales (AMDL, ONCF, OMPIC).

8. Limites et axes d'amélioration

- **Données** : absence de données réelles sur les flux logistiques marocains.
- **Simulation** : la réduction de 15 % appliquée aux secteurs de transport est arbitraire ; on pourrait utiliser des données d'enquête sur le taux de report modal.
- **Améliorations** : intégrer des variables supplémentaires (type de fret, distance, taux de remplissage) pour un modèle plus prédictif.

III. RECOMMANDATIONS MÉTIER

- **Achats responsables** : utiliser le modèle pour comparer l'empreinte carbone de fournisseurs potentiels selon leur secteur NAICS.
- **Logistique** : simuler l'impact d'un changement de mode de transport (route → rail) en réduisant le facteur d'émission des secteurs « Truck Transportation » et en l'augmentant pour le rail.
- **RSE** : intégrer ces prédictions dans les rapports extra-financiers (Scope 3) et dans les objectifs de réduction d'émissions.

IV. Conclusion

Ce projet a permis de développer un modèle prédictif des émissions carbone par secteur d'activité et de simuler des scénarios d'optimisation logistique. Malgré les limites liées aux données, l'approche démontre l'intérêt des outils d'IA pour la décarbonation de la supply chain. Des travaux futurs pourraient l'enrichir avec des données marocaines réelles et des métriques opérationnelles (OTD, taux de remplissage).

Bibliographie / Webographie

- Kaggle dataset : *Supply Chain GHG Emission Factors v1.2*, 2021. [Lien]
- US EPA, *USEEIO model documentation*.
- AMDL, *Plan de Développement Logistique 2030*, Maroc.
- ONCF, données fret ferroviaire (simulées).

Annexes

- Lien vers le dépôt GitHub : https://github.com/loubana28/projet-IA-logistique-verte-Loubna-eddahani-et-Saadoun-noussaiba/upload/main
- Notebook complet (fichier .ipynb)
- Fichier de données (`SupplyChainGHGEmissionFactors_v1.2_NAICS_CO2e_USD2021.csv`)